


Reinforcement Learning

Naf Guo
2026


What is Reinforcement Learning



What is Reinforcement Learning



What is Reinforcement Learning




我们的目标是构建一个代理agent，能够与环境交互并采取智能决策。

其中，环境按不同的时间 t 处于不同的状态 S_t 。我们的代理agent根据所处的环境状态采取行动 A_t 。采取行动会带来两个效果，首先环境的状态会因为和agent的交互发生改变为 S_{t+1} ；其次agent会获得奖励reward R_{t+1} 。我们的目标是最大化奖励的累积，称为总回报return。

return 是从当前时刻到终止时刻的奖励总和，因此只有过程结束后才能得到一个确定的数值。

What is Reinforcement Learning



以电子游戏为例

Agent就是我们操控的游戏角色

动作就是我们用手柄控制游戏角色做出的行为

每一个行为会有reward奖励，比如采取行为后我们赢得了游戏胜利/挖到了金币/击败了敌人，或者保持了游戏角色的存活。


在电子游戏中，游戏屏幕上角色的位置、敌人的位置、地图信息等就是环境的状态了

What is Reinforcement Learning



- Our Agent receives **state** S_0 from the **Environment** — we receive the first frame of our game (Environment).
- Based on that **state** S_0 , the Agent takes **action** A_0 — our Agent will move to the right.
- The environment goes to a **new state** S_1 — new frame.
- The environment gives some **reward** R_1 to the Agent — we're not dead (*Positive Reward +1*).

This RL loop outputs a sequence of **state, action, reward and next state**.



What is Reinforcement Learning

对我们来说，强化学习的目标就是使得累积的奖励最大，我们称为return


$$R(\tau) = r_{t+1} + r_{t+2} + r_{t+3} + r_{t+4} + \dots$$

Return: cumulative reward

Trajectory (read Tau)
Sequence of states and actions

有两种return，一种是无折扣的
是简单的将所有奖励加起来


$$R(\tau) = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \gamma^3 r_{t+4} + \dots$$

Return: cumulative reward

Gamma: discount rate

Trajectory (read Tau)
Sequence of states and actions

一种是有折扣的，未来的奖励要乘小于
1的系数，越远的奖励折扣倍数越大

$$R(\tau) = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

为什么要有折扣？

想象两种方案：

- 1) 今天给你100万，以后每天给你前一天的钱减1，一直减到0为止；
- 2) 今天给你1元，明天给你2元，一直加到某一天给你100万为止。

你愿意选择哪种方案？

What is Reinforcement Learning

Observation Space

State: complete description of the state of the world (no hidden information).



Observation: partial description of the state of the world.



观察空间

环境可以处在不同的状态，这些状态的总和称状态空间

但作为玩家，给定状态，我们只能获得部分信息，我们要基于这部分信息决策；对给定状态，我们能获得一个观察。

What is Reinforcement Learning



动作空间


顾名思义就是我们能采取的所有动作的集合

策略 Policy

The Policy π : the agent's brain

Policy π : is the brain of our Agent, it's the function that tell us what action to take given the state we are.

→ So it defines the agent behavior at a given time.



策略控制着代理的行为。

也就是我们的agent在环境处于状态S时，要采取什么行为。


强化学习的目标是要找到一种最优策略，使我们获得的期望回报最大。

也就是说，策略是一种关系，给定环境的状态，返回代理接下来采取的行动，或者行动分布

$$a_{t+1} = \pi(s_t) \quad \text{or} \quad a_{t+1} \sim \pi(\cdot | s_t)$$

我们希望找到最优策略 π^* ，使得能获得的累积奖励最大

探索与利用的平衡




想象一个情形，我们一直在某家饭店吃饭，并还算满意，现在附近新开了一家饭，我们要不要去尝试一下呢？

我们可以守着已有的经验，还是去旧饭店，但万一新饭店其实非常好吃呢？

我们可以去新饭店尝试，但新饭店可能会很难吃。

这就是一个探索新饭店与利用旧饭店的选择。


贪婪策略 greedy policy



我们只去已经去过的饭店中最好的那家

这就是贪婪策略

Epsilon-greedy策略



我们取一个骰子，如果掷出的数字在3或以上，我们就随机去一家饭店，否则就采取贪婪策略。

这是Epsilon-greedy策略，即Epsilon是一个小于等于1的概率，以Epsilon的概率随机行动，而1-Epsilon的概率采取贪婪策略。

这样通过epsilon的大小来控制探索与利用的平衡