



Reinforcement Learning

Naf Guo
2026

What is Reinforcement Learning




What is Reinforcement Learning



Agent: AI 棋手


What is Reinforcement Learning



Agent: AI 棋手

Environment: 棋盘上所有白子和黑子的位置

What is Reinforcement Learning




Agent: AI 棋手

Environment: 棋盘上所有白子和黑子的位置

Action: 棋手根据棋盘情况下新的棋子

What is Reinforcement Learning



Agent: AI 棋手


Environment: 棋盘上所有白子和黑子的位置

Action: 棋手根据棋盘情况下新的棋子

Reward: 落下的新棋子根据产生的影响可能产生奖励

- 吃掉对方棋子 - 给与正的奖励分数
- 造成己方棋子被吃 - 给与负的奖励分数
- 赢得棋局胜利 - 给与一个相当大的奖励分数

What is Reinforcement Learning



Agent: AI 棋手


Environment: 棋盘上所有白子和黑子的位置

Action: 棋手根据棋盘情况下新的棋子

Reward: 落下的新棋子根据产生的影响可能产生奖励

- ~~吃掉对方棋子~~ — 给与正的奖励分数
- ~~造成己方棋子被吃~~ — 给与负的奖励分数
- 赢得棋局胜利 — 给与一个相当大的奖励分数

What is Reinforcement Learning



Agent: AI 棋手

→ Environment: 棋盘上所有白子和黑子的位置


— Action: 棋手根据棋盘情况下新的棋子

落子动作以及对方棋手落子造成棋盘发生变化，
棋手根据新棋盘落下新棋子

Reward: 落下的新棋子根据产生的影响可能产生
奖励

- ~~吃掉对方棋子—给与正的奖励分数~~
- ~~造成己方棋子被吃—给与负的奖励分数~~
- 赢得棋局胜利—给与一个相当大的奖励分数

What is Reinforcement Learning



Return: 将某时刻开始到棋局结束获得的所有奖励收集起来，称为回报

Agent: AI 棋手

→ **Environment:** 棋盘上所有白子和黑子的位置


— **Action:** 棋手根据棋盘情况下新的棋子

落子动作以及对方棋手落子造成棋盘发生变化，棋手根据新棋盘落下新棋子

Reward: 落下的新棋子根据产生的影响可能产生奖励

- ~~吃掉对方棋子~~ — 给与正的奖励分数
- ~~造成己方棋子被吃~~ — 给与负的奖励分数
- 赢得棋局胜利 — 给与一个相当大的奖励分数

What is Reinforcement Learning



我们的目标是构建一个代理agent，能够与环境交互并采取智能决策。

其中，环境按不同的时间 t 处于不同的状态 S_t 。我们的代理agent根据所处的环境状态采取行动 A_t 。采取行动会带来两个效果，首先环境的状态会因为和agent的交互发生改变为 S_{t+1} ；其次agent会获得奖励reward R_{t+1} 。我们的目标是最大化奖励的累积，称为总回报return。


return 是从当前时刻到终止时刻的奖励总和，因此只有过程结束后才能得到一个确定的数值。

What is Reinforcement Learning




- Our Agent receives **state** S_0 from the **Environment** — we receive the first frame of our game (Environment).
- Based on that **state** S_0 , the Agent takes **action** A_0 — our Agent will move to the right.
- The environment goes to a **new state** S_1 — new frame.
- The environment gives some **reward** R_1 to the Agent — we're not dead (*Positive Reward +1*).

This RL loop outputs a sequence of **state, action, reward and next state**.



What is Reinforcement Learning


对我们来说，强化学习的目标就是使得累积的奖励最大，我们称为回报return


$$R(\tau) = r_{t+1} + r_{t+2} + r_{t+3} + r_{t+4} + \dots$$

Return: cumulative reward

Trajectory (read Tau)
Sequence of states and actions

有两种return，一种是无折扣的
是简单的将所有奖励加起来


$$R(\tau) = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \gamma^3 r_{t+4} + \dots$$

Return: cumulative reward

Gamma: discount rate

Trajectory (read Tau)
Sequence of states and actions

一种是有折扣的，未来的奖励要乘小于
1的系数，越远的奖励折扣倍数越大

$$R(\tau) = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

为什么要有折扣？

想象两种方案：

- 1) 今天给你100万，以后每天给你前一天的钱减1，一直减到0为止；
 - 2) 今天给你1元，明天给你2元，一直加到某一天给你100万为止。
- 你愿意选择哪种方案？

What is Reinforcement Learning

Observation Space

State: complete description of the state of the world (no hidden information).



Observation: partial description of the state of the world.



观察空间

环境可以处在不同的状态，这些状态的总和称状态空间

但作为玩家，给定状态，我们只能获得部分信息，我们要基于这部分信息决策；对给定状态，我们能获得一个观察。

What is Reinforcement Learning



动作空间


顾名思义就是我们能采取的所有动作的集合

策略 Policy

The Policy π : the agent's brain

Policy π : is the brain of our Agent, it's the function that tell us what action to take given the state we are.

→ So it defines the agent behavior at a given time.



策略控制着代理的行为。

也就是我们的agent在环境处于状态S时，要采取什么行为。

强化学习的目标是要找到一种最优策略，使我们获得的期望回报最大。

也就是说，策略是一种关系，给定环境的状态，返回代理接下来采取的行动，或者行动分布

$$a_{t+1} = \pi(s_t) \quad \text{or} \quad a_{t+1} \sim \pi(\cdot | s_t)$$

我们希望找到最优策略 π^* ，使得能获得的累积奖励最大